

Resumen ejecutivo y analítico

Proyecto de Machine Learning

Documento de apoyo para adjuntar junto al notebook principal

Objetivo principal	Sintetizar de forma breve y defendible el desarrollo metodológico del proyecto, desde la definición del problema hasta la evaluación final del modelo.
Documento complementario	Este resumen está pensado para acompañar al notebook técnico, no para sustituirlo.

1. Resumen ejecutivo

Este proyecto aborda un problema de clasificación supervisada en el ámbito de la ciberseguridad, tomando como variable objetivo principal Action Taken. El trabajo se desarrolló con una orientación metodológica y académica, priorizando la comprensión del problema, la interpretación del dataset y la justificación de las decisiones técnicas por encima de la búsqueda de métricas artificialmente altas.

El proceso siguió una secuencia incremental. Primero se validó el dataset y se estudió su estructura; después se revisó su calidad, se realizó un análisis exploratorio apoyado en métricas y visualizaciones y, a partir de ahí, se definió un conjunto de modelado más controlado. Posteriormente se construyó un flujo de preprocesamiento reproducible y se fijó un marco de evaluación claro, utilizando F1 macro como métrica principal, complementada con otras métricas de clasificación.

Como modelo de referencia se utilizó una Regresión Logística baseline, que luego se comparó con Decision Tree, Random Forest y Gradient Boosting. Aunque algunos modelos obtuvieron mejoras puntuales en determinadas métricas, el análisis completo mostró que esas mejoras no siempre se traducían en una mejor capacidad de generalización. En particular, Random Forest logró el mejor valor puntual en test, pero presentó un sobreajuste muy acusado.

La conclusión principal del proyecto es que la Regresión Logística baseline representa la opción más sólida y defendible dentro del contexto de esta práctica, al ofrecer un comportamiento más estable entre entrenamiento y prueba. En conjunto, el trabajo demuestra un uso correcto del flujo de Machine Learning, desde la comprensión del problema hasta la evaluación crítica de resultados.

2. Resumen analítico por fases

Fase 1. Definición del marco del proyecto

La primera fase fijó el marco conceptual y metodológico del trabajo. Se definió el problema como una tarea de clasificación supervisada, se confirmó Action Taken como target principal y se adoptó una metodología incremental. Esta decisión fue clave porque ordenó todo el proyecto y evitó una secuencia improvisada de pruebas sin criterio.

Fase 2. Carga y validación inicial de datos

La segunda fase se centró en cargar correctamente el dataset y validar el punto de partida técnico. Se revisaron dimensiones, primeras filas, nombres de columnas y tipos de datos para garantizar que el notebook trabajara sobre una base estable. Su función fue asegurar que cualquier análisis posterior partiera de datos correctamente leídos y entendidos.

Fase 3. Comprensión estructural del dataset

Una vez cargados los datos, se abordó su comprensión estructural. Se diferenciaron variables numéricas y categóricas y se empezó a interpretar qué papel podía desempeñar cada columna dentro del problema. Esta fase permitió detectar desde el principio que no todas las variables debían tratarse igual y que algunas exigirían una selección más cuidadosa.

Fase 4. Revisión de calidad de los datos

La cuarta fase evaluó la calidad real del dataset. Se revisaron valores nulos, formatos, coherencia de timestamps, validez de IPs y puertos y otras posibles anomalías estructurales. La conclusión fue que el dataset era utilizable, pero exigía limpieza y criterio, algo coherente con el carácter realista de la práctica.

Fase 5. Análisis exploratorio inicial

En esta fase se inició el análisis exploratorio con apoyo estadístico y visual. Se trabajó con distribuciones, tipos de variables, comportamiento del target y primeras gráficas para detectar patrones, desequilibrios y valores extremos. El objetivo fue transformar la información tabular en conocimiento útil para la toma de decisiones posteriores.

Fase 6. Análisis orientado a decisiones de modelado

A partir del EDA, el proyecto pasó de describir a decidir. Se valoró qué variables aportaban señal útil, cuáles podían introducir ruido y qué atributos merecía la pena conservar en el modelado. La decisión central fue priorizar un conjunto de variables defendible y no incorporar columnas por inercia.

Fase 7. Definición del dataset de modelado

La séptima fase formalizó esa selección y definió el dataset de modelado. Se diferenciaron una versión principal y una versión baseline, dejando esta última como referencia más controlada para el entrenamiento oficial. Con ello se ganó trazabilidad y se evitó entrenar modelos sobre conjuntos ambiguos o mal delimitados.

Fase 8. División train/test

La fase 8 resolvió la separación entre entrenamiento y prueba. Se generaron conjuntos X e y consistentes, con tamaños coherentes y sin desalineaciones, lo que permitió pasar del análisis del dataset al experimento de modelado propiamente dicho. Esta fase fue esencial para garantizar una evaluación fiable y evitar fugas de información.

Fase 9. Preprocesamiento

En esta fase se consolidó el preprocesamiento mediante un flujo reproducible. Se clasificaron las variables según su naturaleza, se definieron transformaciones para atributos numéricos y categóricos y se prepararon plantillas listas para integrarse en pipelines. El resultado fue una base técnica limpia, estable y reutilizable para el entrenamiento.

Fase 10. Definición de métricas

La décima fase estableció cómo iba a evaluarse el rendimiento de los modelos. Se fijó F1 macro como métrica principal y se complementó con accuracy, precision macro, recall macro y F1 weighted. Esta elección permitió comparar modelos con un criterio explícito y equilibrado entre clases, evitando depender de una sola cifra aislada.

Fase 11. Entrenamiento del baseline

En la fase 11 se entrenó la Regresión Logística baseline como primer modelo de referencia. Su papel no era lograr el mejor resultado posible, sino ofrecer una línea base sencilla, interpretable y metodológicamente robusta. El resultado fue modesto, pero estable entre entrenamiento y prueba, lo que la convirtió en un punto de partida sólido.

Fase 12. Comparación de modelos

A continuación se comparó el baseline con otros enfoques, como Decision Tree, Random Forest y Gradient Boosting. La comparación mostró que el mejor resultado puntual en test no siempre coincidía con el mejor comportamiento global. En particular, Random Forest logró el mayor F1 macro en test, pero con un sobreajuste demasiado elevado para considerarlo la mejor opción final.

Fase 13. Evaluación visual y analítica del modelo

La fase 13 profundizó en el comportamiento del modelo mediante matriz de confusión, métricas por clase y lectura visual del error. Este análisis permitió ver que el modelo reconocía mejor algunas clases que otras y que seguían existiendo confusiones importantes entre categorías. La evaluación dejó claro que el problema no era trivial y que la interpretación debía ir más allá del promedio global.

Fase 14. Contraste crítico y validación final

La última fase analítica introdujo un contraste crítico con una versión aún más reducida del baseline, concebida como núcleo mínimo. El resultado mostró que simplificar en exceso hacía perder señal útil y empeoraba el rendimiento global frente al baseline oficial. Esta comprobación reforzó la validez de las decisiones previas y confirmó que la versión baseline elegida mantenía un mejor equilibrio.

3. Conclusión final

En conjunto, el proyecto demuestra una metodología correcta y profesional de trabajo en Machine Learning. Se partió de una comprensión clara del problema, se dedicó tiempo al análisis y limpieza de datos, se definió un preprocesamiento reproducible, se eligió un marco de métricas justificable, se compararon varios modelos y se interpretó críticamente el resultado final.

La principal conclusión es que, en este contexto, una solución más sencilla y estable como la Regresión Logística baseline resulta más defendible que modelos más complejos con mejores métricas puntuales pero peor capacidad de generalización. Desde una perspectiva académica, el valor del proyecto reside precisamente en esa capacidad de justificar con criterio cada decisión tomada y de construir una respuesta metodológicamente sólida a un problema realista de clasificación en ciberseguridad.